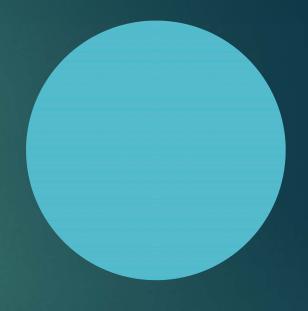
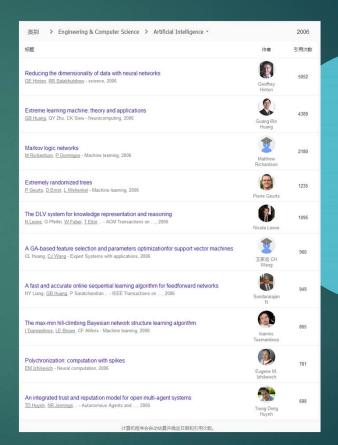
深度极端学习机



极端学习机与深度学习

▶ 深度学习和极端学习机被Google评为 近十年来被引用最多的两篇文章。



深度极端学习机

- 问题和动机:目前的极端学习机方法及其改进的算法主要运用了单隐层的前向反馈神经网络,而没有采用比较流行和有效的层叠泛化准则去寻找输入数据的深层表征。深层模型可以找到高级别的特征表示,从而可以学习出更加抽象的特征,但是目前的深度学习方法需要解决复杂而且非凸的优化问题。
- ▶ 提出了基于极端学习机的层叠模型DrELM,根据层叠泛化准则,采用极端学习机学习深层表征。该模型采用极端学习机作为基本的层构建方法,以随机平移与核化作为层叠的基本元素。

Wenchao Yu, Fuzhen Zhuang, Qing He and Zhongzhi Shi. Learning Deep Representations via Extreme Learning Machine, Neurocomputing, Volume 149, Part A, 3 February 2015, Pages 308-315

极限学习机简介

• 极限学习机 (ELM) 可以写成 $H\beta = T$ 的形式, 其中

$$m{H} = egin{bmatrix} m{h}(m{x}_1) \ dots \ m{h}(m{x}_m) \end{bmatrix} = egin{bmatrix} G(m{a}_1, b_1, m{x}_1) & \cdots & G(m{a}_L, b_L, m{x}_1) \ dots & \ddots & dots \ G(m{a}_1, b_1, m{x}_m) & \cdots & G(m{a}_L, b_L, m{x}_m) \end{bmatrix}$$

$$oldsymbol{eta} = egin{bmatrix} eta_1^T \ dots \ eta_L^T \end{bmatrix}_{L imes c} & and & oldsymbol{T} = egin{bmatrix} oldsymbol{t}_1^T \ dots \ oldsymbol{t}_m^T \end{bmatrix}_{m imes c} \ oldsymbol{t}_{m i$$

• H 是隐层的输出矩阵, $(x_i, t_i) \in \mathcal{R}^d \times \mathcal{R}^c$ 是训练样本集合,G(a, b, x) 是隐层特征的映射函数。 $(a, t_i) \in \mathcal{R}^d \times \mathcal{R}^c$ 是训练样本集合,

极限学习机简介

• 极限学习机 (ELM) 可以写成 $H\beta = T$ 的形式, 其中

$$m{H} = egin{bmatrix} m{h}(m{x}_1) \ dots \ m{h}(m{x}_m) \end{bmatrix} = egin{bmatrix} G(m{a}_1, b_1, m{x}_1) & \cdots & G(m{a}_L, b_L, m{x}_1) \ dots & \ddots & dots \ G(m{a}_1, b_1, m{x}_m) & \cdots & G(m{a}_L, b_L, m{x}_m) \end{bmatrix}$$

$$oldsymbol{eta} = egin{bmatrix} eta_1^T \ dots \ eta_L^T \end{bmatrix}_{L imes c} & and & oldsymbol{T} = egin{bmatrix} oldsymbol{t}_1^T \ dots \ oldsymbol{t}_m^T \end{bmatrix}_{m imes c}$$

• H 是隐层的输出矩阵, $(x_i, t_i) \in \mathcal{R}^d \times \mathcal{R}^c$ 是训练样本集合,G(a, b, x) 是隐层特征的映射函数。

Algorithm 1. Basic ELM.

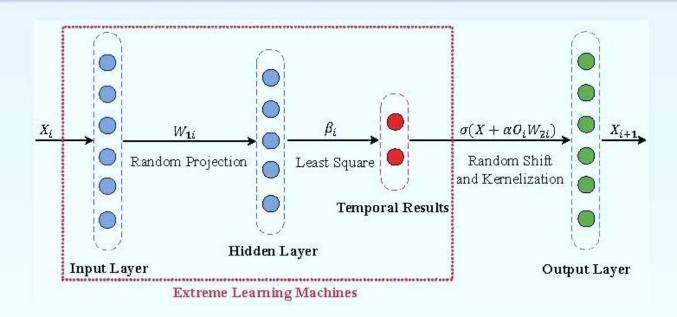
Input: A training set $X = \{(x_i, t_i) | x_i \in \mathbb{R}^d, t_i \in \mathbb{R}^c, i = 1, 2, ..., m\}$, hidden node number L, hidden node transfer function $G(\cdot), j = 1, 2, ..., L$.

Output: The prediction function of ELM for classification and regression.

- (1) Randomly generate hidden node parameters matrix $\mathbf{W} \in \mathcal{R}^{d \times L}$;
- (2) Compute the hidden layer output matrix $\mathbf{H} = G(\mathbf{W}, \mathbf{X})$;
- (3) Compute output weight vector $\hat{\beta} H^{\dagger}T$;
- (4) Compute the result decision function:

$$f(\mathbf{x}) = \mathbf{h}(\mathbf{x})\widehat{\boldsymbol{\beta}} = \mathbf{h}(\mathbf{x})\mathbf{H}^{\dagger}\mathbf{T}.$$

深度极限学习机 (DrELM)



- 首先将输入数据 X_i 随机映射到隐层空间;
- 求解最小二乘问题 $\| \boldsymbol{W}_{1i} \boldsymbol{X}_{i} \boldsymbol{\beta}_{i} \boldsymbol{T} \|$, 从而学习出系数 $\boldsymbol{\beta}_{i}$;
- 基于分类和回归结果 O; 随机平移原始特征, ●并核化 σ(·)。 つへへ

DrELM 算法

- ① 选择模型的深度 $k \in \mathcal{R}$;
- ② 初始化 X₁ = X;
- **3** for i from 1 to k
- **1** 随机生成系数矩阵 $W_{1i} \in \mathcal{R}^{d \times L}$ 和 $W_{2i} \in \mathcal{R}^{c \times d}$;
- 计算隐层输出 $\mathbf{H}_i = \mathbf{X}_i \mathbf{W}_{1i} ;$
- $\mathbf{6}$ 计算输出权重向量 $\widehat{\boldsymbol{\beta}}_i = \boldsymbol{H}_i^{\dagger} \boldsymbol{T}$;
- \mathbf{O} 计算分类或回归结果 $\mathbf{O}_i = \mathbf{H}_i \widehat{\boldsymbol{\beta}}_i$;
- **3** 计算 X_{i+1} : $X_{i+1} = \sigma(X + \alpha O_i W_{2i})$;
- end
- $lacksymbol{\Phi}$ 求解预测函数 $f_k(oldsymbol{X}) = oldsymbol{X}_k oldsymbol{W}_{1k} \widehat{oldsymbol{eta}}_k \circ$

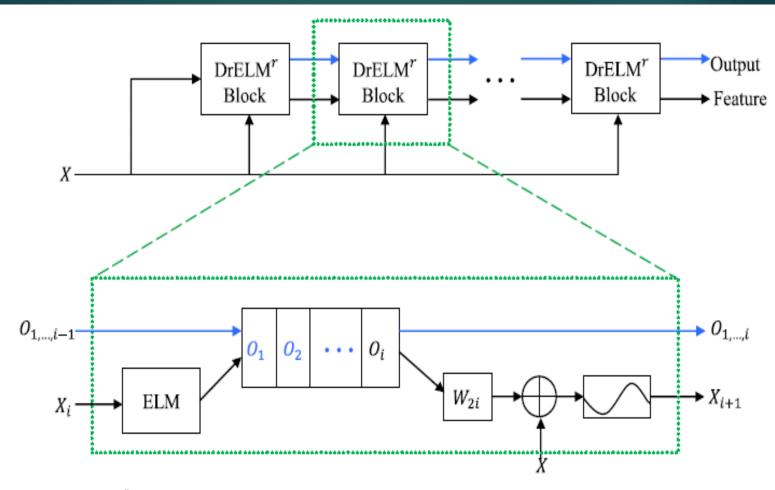


Fig. 2. Illustration of DrELM' paradigm. In recursive version, X_{i+1} updates with all the prediction results in the previous layers $O_1, O_2, ..., O_i$.

Algorithm 2. DrELM.

Input: The training set $\mathbf{X} = [\mathbf{x}^{(1)}, \mathbf{x}^{(2)}, ..., \mathbf{x}^{(m)}]^T$ and $\mathbf{T} = [\mathbf{t}^{(1)}, \mathbf{t}^{(2)}, ..., \mathbf{t}^{(m)}]^T$ corresponding to each training instance, $\mathbf{x}^{(i)} \in \mathcal{R}^d$, $\mathbf{t}^{(i)} \in \mathcal{R}^c$. The hidden node number L.

Output: The prediction function of DrELM for regression or classification.

- (1) Choose model depth k;
- (2) Initial $X_1 X$;
- (3) **for** i from 1 to k
- (4) Randomly generate hidden node parameters matrix $\mathbf{W}_{1i} \in \mathcal{R}^{d \times L}$;
- (5) Compute hidden layer output $H_i X_i W_{1i}$;
- (6) Compute output weight vector $\hat{\beta}_i \mathbf{H}_i^{\dagger} \mathbf{T}$;
- (7) Compute the classification or regression results $\mathbf{O}_i \mathbf{H}_i \widehat{\boldsymbol{\beta}}_i$;
- (8) Randomly generate projection weight $W_{2i} \in \mathcal{R}^{c \times d}$;
- (9) Compute X_{i+1} by Eq. (5): $X_{i+1} = \sigma(X + \alpha O_i W_{2i})$;
- (10) end
- (11) Compute the prediction function $f_k(\mathbf{X}) = \mathbf{X}_k \mathbf{W}_{1k} \widehat{\boldsymbol{\beta}}_k$.

数据集和比较算法

- 数据集:
 - MNIST、CIFAR-10 和来自 UCI repository 以及 StatLib 的 15 个数据集。
- 比较算法:
 - Basic ELM
 - Wernel based ELM
 - 3 Stacked Auto-encoder

模拟数据集上的结果

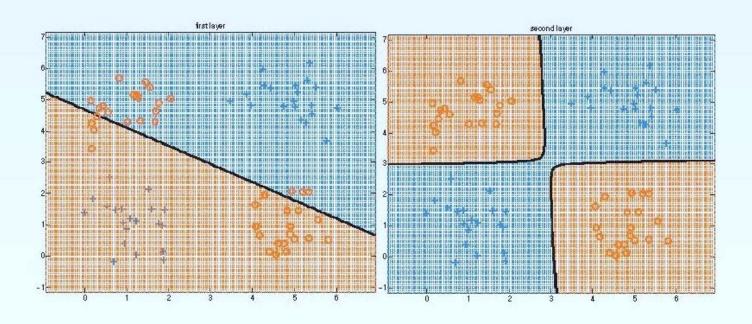


图: XOR 问题的分类超曲面

模拟数据集上的结果

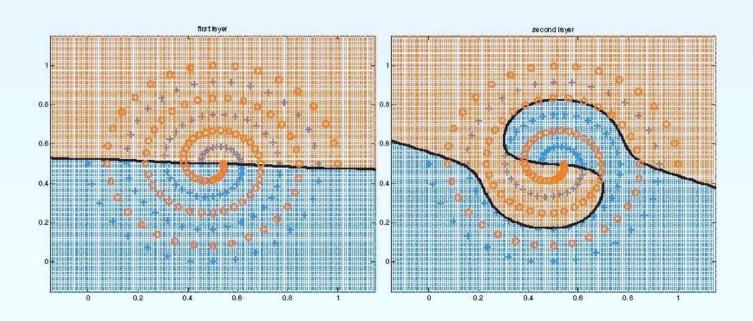


图: Spiral 数据集上的分类超曲面

分类正确率

#	Data Sets	ELM	Kernel based ELM		Stocked	DrELM	DrELM ^r
			Gaussian	Sigmoid	Stacked Autoencoder	DIELIVI	DIETINI.
1	Diabetes	0.7461	0.7684	0.7697	0.7773	0.7791	0.7850
2	Liver	0.6609	0.6776	0.6800	0.6957	0.7527	0.7384
3	Mushroom	0.9409	0.9626	0.9751	0.9979	0.9969	0.9842
4	Adult	0.8430	0.8453	0.8460	0.8406	0.8464	0.8495
5	Iris	0.8200	0.9500	0.9480	0.9640	0.9516	0.9607
6	Wine	0.9831	0.9705	0.9834	0.9852	0.9861	0.9785
7	Segment	0.8675	0.9458	0.9444	0.9532	0.9498	0.9544
8	Satimage	0.7762	0.8599	0.8686	0.8743	0.8505	0.8768
9	MNIST	0.8525	0.9211	0.9176	0.9677	0.9463	0.9520
10	CIFAR-10	0.4034	0.3950	0.4287	0.4327	0.4261	0.4331
	Average	0.7894	0.8296	0.8361	0.8489	0.8486	0.8513

990

回归正确率

表:不同算法在回归数据集的正确率

#	Data Sets	ELM	Kernel based ELM		Ci L I	DELM	D.ELM#
			Gaussian	Sigmoid	Stacked Auto- encoder	DrELM	DrELM*
1	Pyrim	0.1555	0.1320	0.1281	0.1263	0.1231	0.1290
2	Housing	0.1061	0.0866	0.0851	0.0820	0.0843	0.0791
3	Strike	0.0991	0.0984	0.0987	0.0938	0.0927	0.0940
4	Balloon	0.0143	0.0134	0.0126	0.0105	0.0127	0.0124
5	Abalone	0.0958	0.0876	0.0801	0.0747	0.0749	0.0733
	Average	0.0942	0.0836	0.0809	0.0775	0.0775	0.0776

DrELM 的深度

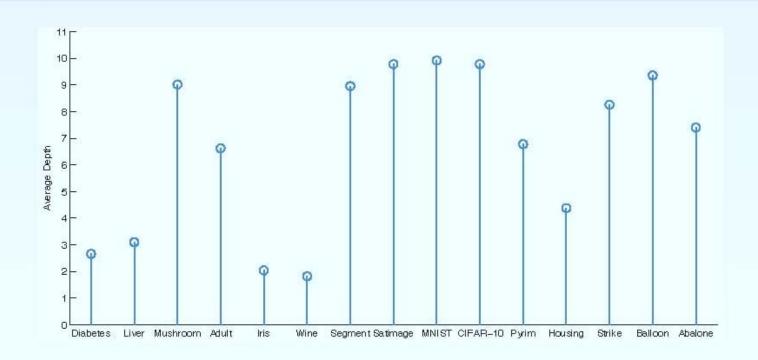


图: DrELM 取得最高预测准确率的时的模型深度

参考文献

 Wenchao Yu, Fuzhen Zhuang, Qing He and Zhongzhi Shi. Learning Deep Representations via Extreme Learning Machine,
Neurocomputing, Volume 149, Part A, 3 February 2015, Pages 308-315

谢谢!